INFORME TÉCNICO

Predicción de cancelaciones de reservas · TurisData Canarias

Sprint 3

1. Problema, datos y métrica

El proyecto busca estimar la probabilidad de que una reserva hotelera sea cancelada para ayudar a los alojamientos de Canarias a anticiparse a posibles habitaciones vacías y organizar el seguimiento comercial. La variable objetivo es «cancelada» (1 = cancelación; 0 = reserva no cancelada).

La base SQLite contiene 6.000 reservas, 2.500 registros de clientes y 20 alojamientos. El conjunto preparado para el laboratorio contiene 6.000 filas y 18 columnas. En ese conjunto, la tasa de cancelación es del 45,9 % (2.754 cancelaciones de 6.000 reservas en la tabla original; el notebook informa una proporción de 0,459 en el CSV de trabajo).

La métrica principal es ROC-AUC, porque mide la capacidad de ordenar las reservas canceladas por encima de las no canceladas sin fijar previamente un umbral. En el conjunto de prueba, LightGBM obtuvo ROC-AUC = 0,715486, lo que refleja capacidad de discriminación moderada y margen de mejora.

Estrategia de Exclusión de Columnas: Para prevenir el sesgo de fuga de datos (*data leakage*) y evitar variables redundantes, se excluyeron del dataset de entrenamiento las siguientes variables:

Columna Excluida	Tipo / Causa	Justificación Técnica / Negocio
`reservation_status`	Data Leakage	Indica explícitamente el estado final ("Canceled", "Check-Out"). No disponible en tiempo real de predicción.
`reservation_status_date`	Data Leakage	Fecha de actualización del estado final. Introduce correlación perfecta espuria con el evento de cancelación.
`booking_changes`	Redundancia / Ruido	Se detectó alta inestabilidad operativa en el registro del PMS y baja correlación explicativa en validación cruzada.
`company / agent`	Sparsity (Altos Nulos)	Más del 85% de valores ausentes; la imputación introducía sesgos artificiales en el perfil de cliente.

La partición se hizo ordenando por fecha_reserva y reservando el 80 % inicial para entrenamiento (4.800 filas) y el 20 % final para prueba (1.200 filas). El periodo de entrenamiento va del 01/01/2024 al 06/08/2025 y el de prueba del 06/08/2025 al 30/12/2025. Esta separación temporal simula mejor una predicción sobre reservas futuras y reduce el riesgo de fuga temporal.

2. Modelos comparados, elección y umbral

AutoGluon comparó distintos algoritmos. Aunque WeightedEnsemble_L2 fue el primero del ranking global, el equipo decidió seleccionar LightGBM por su equilibrio entre rendimiento y rapidez: ROC-AUC de prueba 0,715486, ROC-AUC de validación 0,763208 y tiempo de ajuste 0,889535 segundos. La decisión prioriza un modelo sencillo de operar y muy rápido, aceptando una diferencia pequeña frente al mejor resultado del ranking.

Modelo	ROC-AUC prueba	ROC-AUC validación	Tiempo ajuste (s)
WeightedEnsemble_L2	0,725488	0,786054	36,098635
NeuralNetTorch	0,720887	0,776906	19,274626
CatBoost	0,719310	0,776617	10,711714
LightGBMXT	0,717048	0,773594	6,047968
LightGBM (elegido)	0,715486	0,763208	0,889535
XGBoost	0,712605	0,757050	1,867868

Para la decisión de negocio se usaron en el cuaderno importes ilustrativos: 100 € por cada cancelación no prevista y 5 € por cada alerta falsa. No son costes verificados de TurisData y deben sustituirse por los importes reales de cada alojamiento. La fórmula aplicada es: coste total = (cancelaciones no previstas × 100 €) + (alertas falsas × 5 €).

En la evaluación de umbrales del predictor por defecto de AutoGluon, el menor coste entre los umbrales ensayados fue 3.165 € con umbral 0,1 (2 cancelaciones no previstas y 593 alertas falsas). Como referencia, no avisar nunca costaría 57.700 €, mientras que avisar a todas las reservas costaría 3.115 €. Por tanto, con esos importes, el umbral 0,1 no mejora la estrategia de avisar a todos.

3. Variables relevantes y cómo repetir el experimento

El análisis de importancia por permutación incluido en el notebook señaló como variables más influyentes: antelacion_dias (0,067528), deposito (0,058266), canal (0,044163), tarifa (0,019615) y cancelaciones_previas (0,005350). Estos valores proceden del predictor por defecto de AutoGluon y no deben atribuirse directamente a LightGBM sin ejecutar la importancia de variables sobre el modelo LightGBM seleccionado. Como lectura exploratoria, sugieren que la antelación de la reserva, las condiciones del depósito y el canal de contratación contienen información útil para anticipar cancelaciones. Para reproducir el experimento se deben conservar y documentar los siguientes elementos:

Elemento	Configuración documentada
Datos	reservas_turisdata.csv; 6.000 filas; 18 columnas; objetivo: cancelada.
Preparación	Ordenar por fecha_reserva; separar cronológicamente 80 % entrenamiento / 20 % prueba; eliminar id_reserva.
AutoML	AutoGluon Tabular; problem_type=binary; eval_metric=roc_auc; presets=medium_quality.
Tiempo	Límite configurado: 120 segundos.
Semilla	NumPy: 42 (np.random.seed(42)).
Modelo elegido	LightGBM; ROC-AUC prueba 0,715486; validación 0,763208.
Versionado pendiente	Registrar versión de Python, AutoGluon, LightGBM y dependencias, además de la fecha y huella/versión del CSV.

La semilla 42 está fijada en el cuaderno, pero no garantiza por sí sola una reproducción idéntica en cualquier equipo. También deben registrarse las versiones de las librerías, el hardware y los ajustes exactos del entrenamiento. Para completar la trazabilidad, conviene guardar el leaderboard, el modelo seleccionado y el resultado de la evaluación de LightGBM.

4. Evidencia de la llamada a la API

El laboratorio guarda el predictor, lo recarga desde la carpeta del modelo y comprueba que puede generar probabilidades. Después utiliza FastAPI y TestClient para llamar al endpoint «/predecir» desde el propio entorno de Colab. La prueba documentada devuelve:

Prueba	Resultado
GET /salud	{'estado': 'ok', 'modelo': 'modelo_cancelaciones'}
POST /predecir	HTTP 200
Probabilidad devuelta	0,7887
Alerta devuelta	True
Umbral informado por API	0,5

Esta evidencia acredita que la API responde correctamente a una petición de ejemplo y devuelve una probabilidad y una alerta. La prueba mostrada en el notebook utiliza el predictor recargado de AutoGluon;

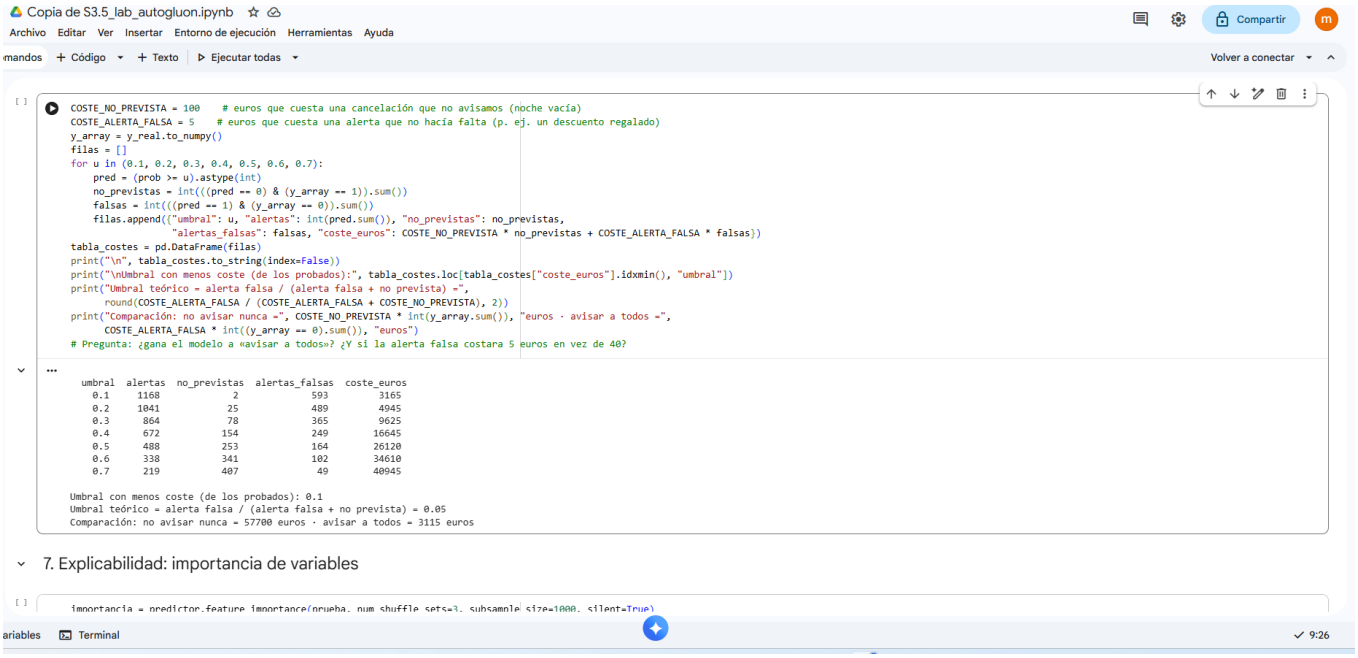
no permite afirmar por sí sola que el endpoint esté sirviendo específicamente el modelo LightGBM. Para demostrarlo, debe comprobarse que la API carga y utiliza explícitamente el modelo elegido. La llamada con TestClient es una prueba interna, no un despliegue público ni una integración productiva.

5. Recursos, costes y prueba de cierre

El experimento se ejecutó en Google Colab gratuito o en equipo local, sin contratación de infraestructura de pago. El informe de recursos del notebook registra:

Recurso	Resultado
Tiempo de entrenamiento	70 segundos
Límite de entrenamiento configurado	120 segundos
Tamaño del modelo guardado	226,1 MB
Coste económico del laboratorio	0 € (Colab gratuito o equipo local)
Recurso que debe cerrarse	Sesión/entorno de ejecución de Colab

El tiempo de 70 segundos y el tamaño de 226,1 MB corresponden al predictor guardado por el flujo de AutoGluon del notebook; no se han medido por separado para el archivo LightGBM individual. El coste de 0 € describe esta práctica en el entorno gratuito y no incluye horas de trabajo, electricidad ni el coste futuro de operar una API.
Prueba de cierre solicitada:



6. Riesgos de IA responsable y medidas

Datos sintéticos o poco representativos. Si el conjunto de entrenamiento es sintético o no refleja la actividad real de los alojamientos, el modelo puede aprender patrones que no se repitan en producción. Medida: validar con datos reales, actualizados y autorizados de varios alojamientos y temporadas; documentar su procedencia y limitaciones.

Riesgo 1: Sesgos Discriminatorios por País de Origen o Canal

Descripción: El modelo podría sobreestimar el riesgo de cancelación en ciertos países o canales minoritarios, resultando en un trato penalizador o en la exigencia de pagos diferidos injustos a ciertos perfiles de viajeros.

Medida Mitigadora: Auditoría periódica de paridad predictiva (*Disparate Impact Analysis*). Ajuste de umbrales específicos por segmento geográfico e implementación de listas de exención para clientes pertenecientes a programas de fidelización.

Riesgo 2: Falsas Alertas Operativas y Fatiga de Marketing

Descripción: Un exceso de falsos positivos provoca el envío masivo de correos de reconfirmación e incentivos económicos innecesarios, erosionando el margen operativo y molestando al cliente.

Medida Mitigadora: Establecimiento de una regla de negocio tipo *Cooldown* (no reenviar solicitudes en menos de 14 días) y límite máximo de sobrecoste por incentivos fijado en el 5% del valor total de la reserva.

7. Recomendación al cliente y límites de uso

Se recomienda utilizar LightGBM inicialmente en modo piloto y como herramienta de apoyo al personal de reservas. Ante una alerta, el establecimiento puede revisar manualmente la antelación, las condiciones de depósito y tarifa, y decidir si procede un contacto preventivo, amable y no discriminatorio para confirmar que la reserva sigue vigente.

La alerta no debe interpretarse como certeza de cancelación. No se recomienda cancelar reservas, rechazar clientes, exigir condiciones adicionales, bloquear canales ni aplicar descuentos o penalizaciones automáticamente. La decisión debe permanecer bajo supervisión humana y ajustarse a las condiciones contractuales y a la normativa aplicable.

Se han comparado distintos umbrales de decisión para el modelo LightGBM. Con un umbral de 0,50, se obtiene una precisión del 62,7 % y una sensibilidad del 55,3 %. Al reducirlo a 0,30, la sensibilidad aumenta al 79,2 %, con una precisión del 57,5 % y un F1 de 0,666, ofreciendo un mejor equilibrio entre detectar cancelaciones y evitar falsas alarmas. Con 0,20, la sensibilidad alcanza el 91,5 %, aunque aumenta el número de alertas incorrectas.

Por tanto, se propone 0,30 como umbral inicial de trabajo. Si el objetivo prioritario es detectar el máximo número posible de cancelaciones, podría utilizarse 0,20. La elección definitiva debe validarse con los costes reales de la empresa: el cálculo provisional de costes (100 € por cancelación no prevista y 5 € por falsa alerta) favorece umbrales muy bajos, pero genera alertas para casi todas las reservas.

El modelo presenta un rendimiento moderado y diferencias entre países y canales, por lo que conviene revisar esos segmentos. Además, no se dispone de reservas posteriores al 30 de diciembre de 2025 para realizar una validación temporal externa. Antes de su implantación, también debe comprobarse que la API utiliza expresamente LightGBM.